Data Storytelling et cadrage du jeu de données FAO

Dans cette première phase, on cherche à comprendre comment raconter une histoire à partir de données, avant de commencer l'analyse et le développement de notre application. Ce document rassemble nos recherches au même endroit. Le README du projet contiendra uniquement une synthèse.

Contexte et objectif du projet

Le sujet Dazzle Dash présente une situation professionnelle : un directeur marketing souhaite accéder rapidement à des informations importantes grâce à une application de visualisation. L'enjeu est donc de ne pas seulement afficher des graphiques, mais de rendre les résultats compréhensibles pour une personne qui n'est pas spécialiste des données.

Le sujet demande de définir le Data Storytelling, d'en trouver un exemple parlant et de documenter ce travail. Il propose également plusieurs jeux de données publics pour construire une preuve de concept. On a choisi d'orienter le projet vers les données alimentaires de la FAO, avec le jeu de données intitulé "Who eats the food we grow?".

Comprendre le Data Storytelling

Définition

Le Data Storytelling, ou mise en récit des données, consiste à communiquer une information à partir de données en associant une analyse, des représentations visuelles et une narration.
L'objectif est d'aider le public à comprendre ce que les données montrent, ce qui est important et pourquoi ces résultats méritent son attention.

Ce que l'on retient de nos recherches, c'est qu'un graphique ne raconte pas automatiquement une histoire.
Il peut être exact et lisible, mais laisser le lecteur sans explication.
Le Data Storytelling ajoute un fil conducteur : une question de départ, des observations, des éléments de contexte et une conclusion fidèle aux résultats.

Les éléments essentiels

Les données :
Elles constituent la base factuelle de l'histoire.
Elles doivent être suffisamment fiables et adaptées à la question étudiée.

La visualisation :
Elle rend les comparaisons, les tendances ou les différences plus faciles à percevoir.

La narration :
Elle organise les informations, explique les graphiques et met en avant un message principal.

Le contexte et le public :
Ils orientent le niveau de détail, le vocabulaire et les graphiques choisis.

Ces éléments fonctionnent ensemble.
Une narration convaincante ne doit jamais remplacer la rigueur de l'analyse : je dois distinguer ce que les chiffres prouvent, ce qu'ils suggèrent et ce qu'ils ne permettent pas de conclure.

DIFFÉRENCE ENTRE DATA VISUALISATION ET STORYTELLING

Data Visualisation et Data Storytelling

Data Visualisation	Data Storytelling
Transformer des valeurs en graphiques, cartes ou tableaux	Construire une explication à partir de visualisations et de données
Aider à explorer les résultats et à repérer des tendances	Guider le public vers une information ou un message important
Répondre surtout à “Que voit-on ?”	Répondre aussi à “Que faut-il comprendre ?”

Par exemple, un graphique montrant les quantités de céréales utilisées par différents pays est une visualisation.
Si je le présente avec une question précise, que j’explique les écarts et que je replace les résultats dans leur contexte, je commence à construire une histoire à partir des données.

On en retient qu’un tableau de bord interactif n’est pas automatiquement du Data Storytelling.
Pour notre application Dash, il faudra sélectionner les graphiques utiles et accompagner les résultats de textes courts, compréhensibles et prudents.

CONSTRUCTION DU DATA STORYTELLING

Comment construire une histoire avec des données ?

Pour nous aider à structurer une analyse destinée à un public non technique, on retient la démarche suivante :

- Partir d'une question claire : par exemple, comment évolue l'utilisation des ressources alimentaires selon leur destination ?

- Explorer les données avant d'écrire une conclusion : vérifier les variables, les valeurs manquantes et les limites du jeu de données.

- Choisir un graphique adapté au message : évolution dans le temps, comparaison entre pays ou répartition par catégorie.

- Ajouter des titres explicites, des unités, une légende et un commentaire qui aide à interpréter le résultat.

- Conclure sans aller au-delà de ce que les données permettent d'affirmer.

Il faut également éviter de multiplier les graphiques sans objectif précis.
Un petit nombre de visualisations bien expliquées peut être plus utile qu'un tableau de bord très chargé.

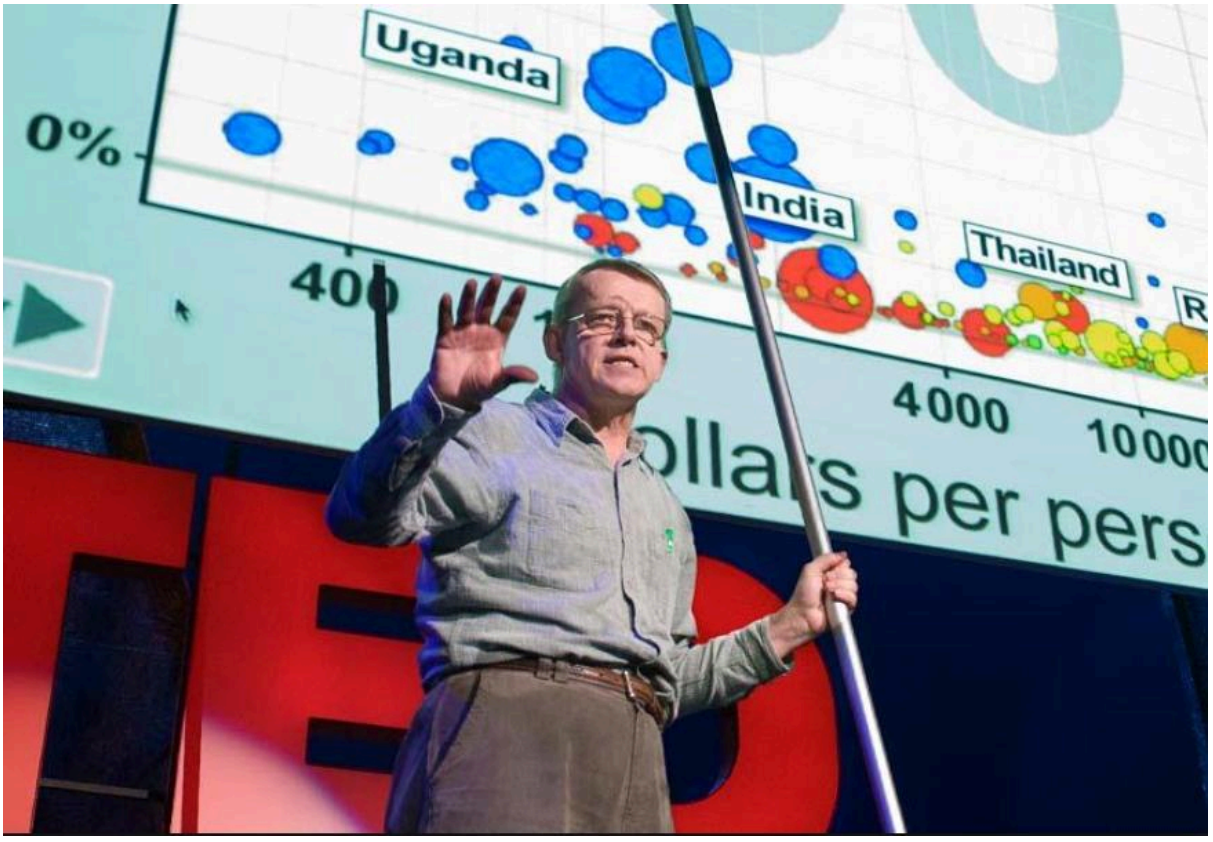
Exemple étudié : Hans Rosling et Gapminder

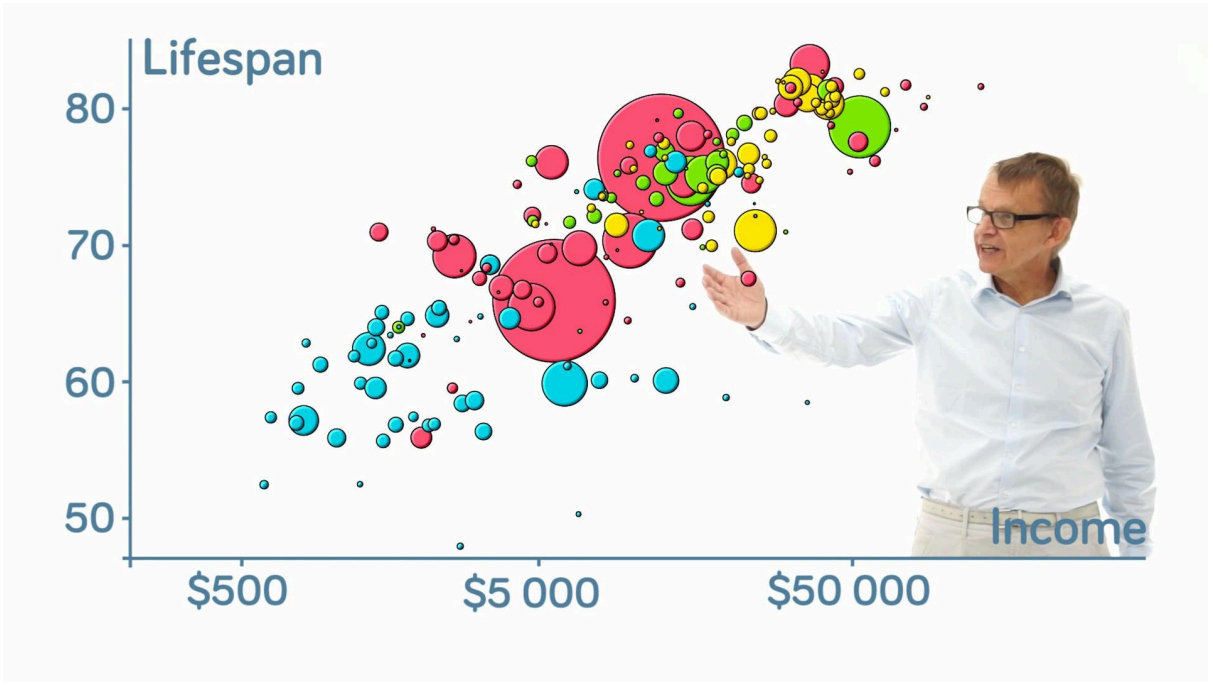
L'exemple qui nous a le plus aidée à comprendre la mise en récit des données est celui de Hans Rosling, notamment la présentation "200 Years That Changed the World" réalisée avec Gapminder.

Dans cette présentation, Hans Rosling utilise un graphique animé pour montrer l'évolution de l'espérance de vie et du revenu dans différents pays sur une longue période.
Chaque bulle représente un pays : sa position correspond aux indicateurs observés, sa taille représente la population et sa couleur aide à distinguer des groupes de pays.

L'intérêt ne vient pas uniquement de l'animation.
Hans Rosling commente les déplacements des bulles, donne des repères historiques et attire l'attention du public sur des changements importants.
Les données deviennent ainsi le support d'un récit que l'on peut suivre.

Ce que cet exemple nous apprend pour Dazzle Dash : une visualisation peut être interactive et riche en informations, mais elle sera plus accessible si l'on guide la lecture et si nous formulons clairement le message qu'on souhaite faire passer.




Lifespan
80
70
60
50
$500
$5 000
$50 000
Income


90
80
70
60
50
40
30
LIFESPAN
2012
INCOME
$1
$10
$100

Application au thème FAO

Choix du jeu de données

Pour la suite du projet, on retient le jeu de données “Who eats the food we grow?”, mentionné dans l’énoncé.
Le thème s’intéresse à la manière dont les ressources agricoles sont utilisées, en particulier pour l’alimentation humaine et animale.
La source de données est liée aux statistiques de l’Organisation des Nations unies pour l’alimentation et l’agriculture (FAO).

Le jeu de données est référencé sur Kaggle sous le nom “World Food / Feed Production”.
La période 1961–2013 apparaît dans sa présentation ; on devra la confirmer lors de la récupération du fichier.
À ce stade, on n'a pas encore ouvert, contrôlé ni nettoyé les données.
Les variables effectivement disponibles seront donc vérifiées au début de la phase d’analyse.

Notions à ne pas confondre

Notion	Signification pour notre projet
Production alimentaire	Quantité produite sur un territoire
Disponibilité alimentaire	Quantité estimée comme disponible pour certains usages, après prise en compte des flux et affectations pertinents
Consommation réelle	Quantité effectivement consommée par les personnes ; elle n’est pas automatiquement mesurée par un bilan de disponibilité
Alimentation animale (feed)	Part des produits agricoles affectée à l’alimentation des animaux, selon la définition du dataset

Cette distinction est importante, car une quantité destinée à l’alimentation humaine ne signifie pas nécessairement qu’elle a réellement été mangée.
Je vérifierai les définitions exactes des colonnes et les unités avant toute interprétation.

Problématique de travail

Notre question générale sera : “Comment l’utilisation des ressources alimentaires pour les humains et les animaux varie-t-elle dans le temps et entre les pays ?”

Cette formulation reste provisoire : elle sera ajustée si le contenu du dataset ne permet pas certaines comparaisons.
Elle nous donne toutefois une direction pour explorer les données et imaginer une narration cohérente.

Pistes d’analyse à vérifier

- Observer l’évolution des quantités destinées à l’alimentation humaine et animale dans le temps.

- Comparer certains pays ou régions, à condition de disposer de catégories et d’unités comparables.

- Repérer les denrées les plus représentées dans chaque usage.

- Étudier des proportions en plus des quantités brutes, si cela est pertinent et techniquement possible.

Ces questions sont des hypothèses de travail, pas des résultats. On ne pourrait conclure qu’après l’exploration du fichier et l’analyse statistique.

CONCLUSION & REFERENCES

Ce qu'on retient pour la conception de Dazzle Dash

Le directeur marketing de notre scénario doit pouvoir comprendre rapidement les résultats.
Nous souhaitons donc créer une application avec des titres formulés comme des messages, des graphiques adaptés, des filtres utiles et de courts textes d'interprétation.
La narration devra aider l'utilisateur à suivre les principaux résultats sans lui imposer de maîtriser les méthodes statistiques.

Nous veillerons aussi à expliquer les limites des données, notamment les différences entre production, disponibilité et consommation.
Notre objectif sera de rendre l'analyse accessible sans simplifier au point de donner une interprétation trompeuse.

Conclusion de la phase

Cette première phase nous a permis de comprendre que le Data Storytelling repose autant sur la qualité de l'analyse que sur la manière de présenter les résultats.
Nous retenons surtout la nécessité de partir d'une question, de construire un fil conducteur, de choisir des visualisations pertinentes et d'expliquer leurs limites.

On a également défini le thème général du projet autour du dataset FAO.
La prochaine phase portera sur la découverte de Dash et Plotly ; l'examen réel du dataset et son nettoyage viendront ensuite, conformément à notre plan de travail.

Sources et références

- Le sujet : Dazzle Dash

- Nations unies, UN Statistics Division — Data Storytelling : https://unstats.un.org/sdgs/data-storytelling/

- Statistique Canada — Ressources sur la littératie des données : https://www.statcan.gc.ca/en/wtc/data-literacy

- Gapminder — 200 Years That Changed the World : https://www.gapminder.org/videos/200-years-that-changed-the-world/

- FAOSTAT — Portail de données agricoles de la FAO : https://www.fao.org/faostat/

- Kaggle — World Food / Feed Production : https://www.kaggle.com/datasets/dorbicycle/world-foodfeed-production